

ESTIMACIONES DE ENTRENAMIENTO Y RECURSOS

Arquitectura propuesta

- 1. **Procesamiento específico por modalidad (early fusion)**
 - **Esqueletos (pose sequences):** Encoder basado en Temporal Graph Neural Network (TGNN) o Spatio-Temporal Transformer. Cada frame se representa como grafo (nodos = joints). Salida: embeddings por frame o ventana.
 - **Audio ambiental:** Encoder ligero tipo 1D-Conv/TDNN o wav2vec-style pequeño (posiblemente preentrenado de forma contrastiva). Reducción a tokens por ventana temporal.
 - **Localización/zona:** Embedding posicional (bins aprendidos o coordenadas continuas + MLP).
- 2. → Motivo: separar modalidades reduce la complejidad del bloque de fusión y respeta la naturaleza de cada señal.
- 3. **Fusión multimodal (cross-attention)**
 - Concatenación de secuencias (tokens de pose + audio + ubicación) → Transformer multimodal con atención cruzada.
- 4. **Objetivo principal**
 - Clasificación supervisada binaria: “altercado inminente” vs “no altercado” (probabilidad continua).
- 5. **Tamaño recomendado del modelo**
 - Pequeño (prototipo/edge): ~100 M parámetros
 - Medio (punto de partida óptimo): ~1 B parámetros → mejor equilibrio capacidad/coste
 - Grande (si hay muchos datos y se busca SOTA): 3–5 B parámetros

Supuestos cuantitativos clave

Parámetro	Valor usado
Fórmula FLOPs entrenamiento	$\approx 6 \times N_{\text{params}} \times N_{\text{tokens}}$ (estándar Transformer)
Tokens por segundo	100 tok/s (coarse) y 1 000 tok/s (fina)
Tamaños de dataset	1 000 h (pequeño) 5 000 h (medio) 20 000 h (grande)
GPU objetivo	NVIDIA H100 (rendimiento efectivo sostenido $\approx$ 500 TFLOPS en FP16/FP8)
Precio H100 (2025)	\$3–6–10 / GPU-hora (spot / estándar / premium)
Consumo medio por GPU (incl. overhead)	$\approx$ 412 W
Factor de emisiones España	0,108 – 0,283 kgCO ₂ /kWh
Multiplicador por iteración/desarrollo	$\times 1,5 - \times 2 - \times 3$

Resultados resumidos (modelo medio 1 B parámetros, dataset medio 5 000 h)

Escenario	Tokens/s	FLOPs totales	GPU-horas (acumuladas)	Wall-time (8×H100)	Energía	Coste nube (rango)	CO ₂ (España)
Coarse (100 tok/s)	100	1,08×10 ¹⁹	~60 h	~7,5 h	~25 kWh	\$180–600	2,7–7 kg
Fina (1 000 tok/s)	1 000	1,08×10 ²⁰	~600 h	~75 h	~247 kWh	\$1 800–6 000	27–70 kg

- Modelo 3 B parámetros (misma configuración 1 000 tok/s): ×3 → 1 800 GPU-horas (~225 h wall-time en 8×H100), coste \$5 400–18 000 + iteraciones.
- Con factor ×2 de desarrollo típico: duplicar los valores anteriores.

Conclusión económica: incluso en la configuración más exigente (3 B + alta resolución), entrenar desde cero o hacer fine-tuning completo sigue siendo muy asequible (< \$20 k con iteraciones) comparado con LLMs grandes.

Datasets disponibles y alternativas éticas

Datasets públicos útiles

Dataset	Modalidad	Licencia / uso permitido	Comentario
Human3.6M	3D poses	Académico	Excelente para pose estimation
CMU Panoptic / Mocap	3D mocap multi-view	Investigación	Generación sintética
NTU RGB+D 60/120	RGB + Depth + 3D skeleton	Académico / no comercial	Acción recognition + skeletons
RWF-2000	Vídeo violencia real	Restringido (revisar)	Benchmark de violencia en vigilancia
XD-Violence	Audio + vídeo	Investigación	Multimodal, gran escala
AudioSet (Google)	Audio eventos	CC BY 4.0	Gritos, golpes, caídas

Estrategias para evitar riesgos legales y de privacidad (RGPD / AI Act)

Dado que el uso de grabaciones reales de prisiones plantea serios problemas (datos biométricos, categorías especiales art. 9 RGPD, contexto de alto riesgo), proponemos el siguiente enfoque escalonado:

1. Datos sintéticos y simulación

- Generación masiva de altercados con motores mocap (Unreal Engine, Blender, etc.) + física realista.

- Control total de etiquetas y variabilidad (ropa, iluminación, número de personas).
- 2. **Grabaciones controladas con consentimiento**
 - Simulaciones con actores o personal penitenciario voluntario (consentimiento informado y revocable).
- 3. **Transfer learning seguro**
 - Pre-entrenamiento en datasets públicos → fine-tuning mínimo (o nulo) con datos reales anonimizados y bajo DPIA estricta.

Conclusión legal provisional: hasta 2029 no asumimos que almacenar únicamente esqueletos nos exima del RGPD. Por tanto, la estrategia principal será 100 % sintética + voluntarios hasta que exista claridad regulatoria definitiva.

Evaluación y métricas

Objetivos operativos

- Detectar altercados inminentes con antelación suficiente (> 3–5 s) para intervención humana.
- Minimizar fatiga de alertas y respetar privacidad.

Métricas principales

Métrica	Descripción	Prioridad
Recall @ violencia	% de eventos reales detectados	Crítica
Precision	% de alarmas correctas	Alta
F2-score	Balance con peso en recall	
AUPRC	Área bajo curva Precision-Recall (clase rara)	Alta
False Alarm Rate (FAR)	Falsas alarmas por cámara y hora	Crítica
Detection lead time	Segundos de antelación media	Alta
Latencia inferencia (p95)	Tiempo desde captura hasta alerta	≤ 2 s objetivo

Umbral de aceptación (Go/No-Go)

Nivel	Recall	Precision	FAR (por cámara/24h)	Lead time	Latencia p95	Robustez (degradación)
A – Piloto controlado	≥ 0,85	≥ 0,40	≤ 2 FP	≥ 3 s	≤ 5 s	< 30 %
B – Despliegue limitado	≥ 0,90	≥ 0,60	≤ 1 FP	≥ 4 s	≤ 3 s	< 20 %
C – Despliegue a escala	≥ 0,95	≥ 0,70	≤ 0,25 FP	≥ 5 s	≤ 2 s	< 10 % + fairness

Pruebas obligatorias antes de producción

1. Piloto real de 1–3 meses con operadores humanos y medición de KPIs operacionales.
2. DPIA actualizada y auditoría de privacidad.
3. Auditoría de bias y fairness por subgrupos.
4. Stress-test 24/7 y medición de drift.
5. Plan de rollback, monitoring continuo y SLA definido.

Con esta hoja de ruta técnica, económica y ética, el proyecto es viable, escalable y defendible tanto técnica como jurídicamente.