

ESPECIFICACIÓN V3 | GRUPO PRISION RISK-AI

Ruta Github Prision Risk-AI: sprint3/ con especificación ampliada del debate anterior y ampliación de los contenidos de esta especificación.

Estimación del entrenamiento: hardware, coste y huella de carbono

- Modelo grande: 3B parámetros
- Dataset medio: 5.000 h
- Alta resolución temporal: 1000 tokens/s
- Coste en la nube alto: 10 \$/GPU-h
- Iteración de desarrollo ×3 (caso extremo)
- Nodo de entrenamiento: 8× NVIDIA H100
- FLOPs totales $\approx 1.08 \times 10^{20}$
- GPU-hours acumuladas ≈ 180 h
- Coste base: 1.800 \$
- Coste con iteración ×3: ≈ 5.400 \$
- Energía consumida ≈ 74.25 kWh
- Huella de CO₂ (España): 8–21 kgCO₂ según mix energético

Datasets disponibles y obtención de datos faltantes

- CMU Panoptic (poses 3D)
- Human3.6M (poses humanas)
- NTU RGB+D (acciones/anomalías)
- AudioSet (audio ambiental)
- OpenViolence (violencia contextual)

Sobre **datos penitenciarios reales**, se considera que técnicamente podrían utilizarse siempre que estén desidentificados, pero no es una opción segura por defecto, ya que incluso secuencias de esqueletos pueden presentar riesgos residuales de reidentificación o sesgos contextuales no controlados.

Por ello, la estrategia recomendada para cubrir patrones propios de prisiones es:

- Simulaciones multi-agente realistas (violencia, interacción, agitación, dinámicas grupales)
- Vídeos anonimizados por esqueletización, sin conservar imagen RGB
- Registros disciplinarios agregados, no individuales
- Generación de variaciones sintéticas (perturbaciones, distintos layouts espaciales, oclusiones)

Evaluación del modelo y criterios go/no-go

- AUC-ROC > 0.90
- F1 > 0.85
- Falsos positivos < 12 %
- Falsos negativos < 8 %
- Equalized Odds: diferencia < 5 % entre grupos
- Latencia < 500 ms en inferencia

El modelo se evalúa inicialmente con benchmarks como **NTU RGB+D** y **UCSD Anomaly Detection**, y posteriormente con pruebas internas controladas.

Criterio go/no-go:

El sistema solo puede pasar a producción si cumple todas las métricas anteriores simultáneamente, si supera auditorías externas de sesgo y si las pruebas manuales de revisión indican ausencia de patrones peligrosos (falsos positivos en exceso, correlaciones espurias, dependencia excesiva de ruido o posición).

En caso de fallo, se reentrena ajustando pesos, equilibrando el dataset, revisando el proceso de esqueletización o incorporando regularización adicional.

Riesgos éticos y sociales

A gran escala (p. ej., uso equivalente a >1 millones de personas en Europa), incluso un 1 % de error generaría miles de consecuencias negativas. Los principales riesgos incluyen: alertas injustas dirigidas a internos vulnerables, incremento de medidas disciplinarias sin justificación sólida, sobrecarga del personal por falsas alarmas y sesgos estructurales contra personas con patrones motores atípicos (edad, discapacidad, efectos de medicación). Estos problemas pueden amplificarse si ciertos grupos están poco representados en los datasets de acción, lo que conduce a un rendimiento desigual.

Entre los colectivos beneficiados se encuentran los funcionarios, que obtienen una mejor conciencia situacional, y el sistema penitenciario, que gana en capacidad de prevención. En cambio, los más afectados serían los internos con movimientos alejados del “patrón estándar”, así como minorías no suficientemente reflejadas en los datos de entrenamiento. Esto refuerza la necesidad de auditorías continuas, revisión humana obligatoria y límites estrictos en el alcance del sistema.

Postura macro: accelerationists, safetyists y skeptics

El equipo adopta una postura **safetyist**, centrada en promover innovación responsable dentro de límites claros. La posición se basa en cuatro principios: **transparencia**, **verificabilidad**, **auditoría externa independiente** y **restricción jurídica** del uso a finalidades legítimas y supervisadas. Esto se traduce en decisiones de diseño concretas: el **modelo** debe ser **explicable y trazable**, evitando arquitecturas de “caja negra”; se establece la prohibición de usos secundarios, como vigilancia individual o identificación personal; todas las alertas requieren supervisión humana; y se prioriza el uso de modelos de tamaño moderado, evitando complejidades innecesarias.

Robustez y posibles intentos de ruptura (jailbreaks)

- **Movimientos erráticos intencionales:** alerta de riesgo bajo y solicitud de revisión humana.
- **Saturación acústica con golpes o ruidos repetidos:** reducción de la confianza del modelo y alerta técnica de “ruido atípico”.
- **Patrones repetidos frente a cámaras para sesgar la detección:** activación de filtros anti-adversarial.
- **Bloqueo parcial de cámaras:** aviso de “oclusiones anómalas” y transferencia a modo degradado.
- **Ropa con marcadores o patrones diseñados para confundir la pose:** uso de detección temporal robusta para compensar.
- **Simulación de peleas coreografiadas:** validación cruzada entre audio y movimiento para confirmar riesgo real.
- **Intentos de obtener información personal mediante prompts:** rechazo automático y recordatorio de que el sistema no procesa identidades.
- **Intentos de activar acciones automáticas o forzar decisiones:** denegación automática, ya que el sistema carece de capacidades de control físico.
- **Manipulación extrema de iluminación o sombras:** normalización visual y alerta técnica al operador.
- **Preguntas o ataques para descubrir vulnerabilidades del modelo:** respuesta segura sin revelar superficies de ataque.

Referencias

Conversación ChatGPT (2025). Estimación del entrenamiento
<https://chatgpt.com/share/691c53df-3488-800d-9d86-60785b940738>

Referencias externas

Parlamento Europeo & Consejo de la UE. (2024). *AI Act – EU Artificial Intelligence Regulation.*
<https://artificialintelligenceact.eu/es/ai-act-explorer/>

CMU Panoptic Dataset. (poses 3D y acciones humanas).
<http://domedb.perception.cs.cmu.edu/>