

2. Casos de uso previstos y no previstos

2.1. Usos previstos

PrisonRisk-AI se diseña como un **sistema de IA de alto riesgo** según la IA Act (Anexo III), orientado a la **prevención de altercados en prisiones**. Sus usos previstos, alineados con la normativa citada en el documento ([AI Act – Maldita.es](#), [AI Act Explorer](#)), son:

1. **Generación de alertas interpretables de riesgo de conflicto**
 - Detectar **patrones de tensión o violencia inminente** a partir de datos multimodales (esqueletos de movimiento, rasgos acústicos abstractos, densidad de grupo, proximidad inusual, etc.).
 - Cada alerta incluye una **explicación clara de sus causas**, usando técnicas de IA explicable (por ejemplo, aproximaciones tipo SHAP/LIME, como se refleja en el mockup de arquitectura: “Motor de Alertas y Explicabilidad – SHAP/LIME → alerta + motivo”).
 - Esto responde a las exigencias de **transparencia y explicabilidad del art. 13 IA Act**.
2. **Apoyo a la toma de decisiones humanas en vigilancia preventiva**
 - Funcionar **siempre bajo control humano**, cumpliendo el requisito de **supervisión efectiva** (art. 14 IA Act):
 - El sistema **solo emite alertas**, la decisión final siempre corresponde a un funcionario.
 - Todas las alertas quedan registradas para **trazabilidad y derecho de reclamación**.
 - Facilitar que el personal penitenciario pueda **priorizar intervenciones** en zonas o momentos de mayor riesgo.
3. **Mejora de la conciencia situacional del centro penitenciario**
 - Proporcionar una **vista global** por módulos (normal / tensión / riesgo alto), como se ilustra en el mockup GUI del documento (“PrisonRisk-AI – Normal / Tensión / Riesgo alto – Alertas recientes”).
 - Servir para **identificar patrones agregados** (por ejemplo, determinadas horas o módulos con mayor frecuencia de alertas), sin perfilar individualmente a los internos.
4. **Soporte a la evaluación interna y auditoría del sistema**
 - Utilizar los **metadatos de alertas** (sin datos biométricos personales) para:
 - Evaluar **métricas de rendimiento** (AUC-ROC, F1, tasas de falsos positivos/negativos) descritas en el documento.
 - Monitorizar **sesgos y equidad** mediante métricas como Equalized Odds (< 5 % de diferencia entre subgrupos, tal y como se recoge en el apartado de evaluación).
 - Estos usos permiten cumplir con las obligaciones de **gestión de riesgos y documentación técnica** (arts. 9–11 IA Act) y con el **principio de responsabilidad proactiva** del RGPD ([Youreurope – Data Protection, LOPD-RGPD](#)).

Usuarios previstos (actores)

De acuerdo con la especificación (sección 1 del documento y punto 8 sobre usuarios y colectivos afectados), los usuarios previstos son:

- **Administración penitenciaria (Ministerio del Interior y direcciones de centro)**
 - Define las **políticas de uso**, marcos de supervisión y auditoría.
 - Es corresponsable con el proveedor según el art. 26 RGPD (mencionado en la sección de rendición de cuentas).
- **Funcionarios y vigilantes de prisiones**
 - Usuarios operativos principales del sistema.
 - Reciben las alertas, **verifican la situación real** y toman decisiones (aceptar/descartar, tipo de intervención).
 - Su rol está en línea con el requisito de **supervisión humana efectiva** de la IA Act.
- **Delegado de Protección de Datos (DPO) y órganos de cumplimiento**
 - Supervisan el cumplimiento del **RGPD y la LOPD-GDD**, realizan la **Evaluación de Impacto (EIPD)** y tienen capacidad de activar el “**botón de parada**” en caso de riesgos graves (tal y como se recoge en el punto 7 de tu documento).
- **Internos de los centros penitenciarios**
 - No son usuarios directos, pero sí el **colectivo supervisado y afectado** por el sistema.
 - Las salvaguardas legales y técnicas (anonimización, no uso de biometría real, ausencia de decisiones automáticas) se diseñan para proteger sus derechos, incluidos el **principio de reinserción** (art. 25.2 CE, con referencias doctrinales enlazadas en tu documento).

2.2. Usos no previstos / out-of-scope

Conforme al posicionamiento **safetyist** del equipo y al marco RGPD + IA Act que se cita a lo largo del documento, PrisonRisk-AI **no está diseñado ni debe utilizarse** para:

1. **Tomar decisiones automáticas con efectos jurídicos o disciplinarios**
 - No puede **imponer sanciones, aislamiento, cambios de módulo o clasificación de régimen** sin intervención humana.
 - Se alinea con la prohibición de decisiones automatizadas sin garantías reforzadas en contextos de alto riesgo y con la necesidad de intervención humana significativa (principios RGPD y IA Act).
2. **Identificar o autenticar personas (biometría)**
 - No realiza **reconocimiento facial, identificación por voz u otros biométricos**, de acuerdo con las advertencias de la Comisión Europea, EDPB y EDPS sobre tratamiento de imágenes y datos biométricos en contextos sensibles (referencias legales que citas en la parte de “Tratamiento de imágenes/lecturas biométricas de presos”).
 - El sistema trabaja con **esqueletos digitales y rasgos acústicos abstractos**, que se diseñan para **no ser usados con fines de identificación** (evitando caer en el ámbito del art. 9 RGPD sobre categorías especiales).
3. **Generar pruebas judiciales o disciplinarias**

- Las alertas del sistema **no se conciben como prueba principal** en expedientes disciplinarios o procedimientos judiciales.
 - Se usan como **herramienta indicativa**, que debe ser contrastada con otras fuentes (testimonios, vídeos originales, actas), evitando convertirse en un “tribunal algorítmico”.
4. **Monitorización personalizada o perfilado individual**
- El sistema se centra en **contextos y situaciones**, no en personas concretas:
 - No genera **ranking de peligrosidad individual**.
 - No mantiene historiales de “riesgo” por interno, en coherencia con el principio de reinserción y con la crítica doctrinal a la estigmatización permanente (referencias sobre el art. 25.2 CE incluidas en tu documento).
5. **Uso fuera del entorno penitenciario definido**
- No está pensado para ser desplegado en **espacios públicos, transporte, empresas, escuelas u otros entornos**.
 - El ámbito de aplicación se limita a **prisiones de media y alta seguridad en España**, bajo el régimen jurídico específico indicado en las referencias RGPD/LOPD-GDD y IA Act.
6. **Control físico directo de infraestructuras o medidas coercitivas**
- PrisonRisk-AI no controla puertas, celdas, barreras físicas ni dispositivos de contención.
 - Cualquier acción material queda en manos del personal humano, en consonancia con la exigencia de **supervisión humana real** de sistemas de alto riesgo (IA Act, art. 14).

2.3. Usos no recomendados y mal-usos previsibles

Aunque algunos de los siguientes escenarios puedan ser **técnicamente posibles**, se consideran **malos usos** o **usos no recomendados** que entran en conflicto con los principios recogidos en el documento (transparencia, verificabilidad, auditoría externa, restricción jurídica del uso):

1. **Etiquetar internos como “peligrosos” o crear listas negras**
 - Utilizar las alertas para elaborar **perfiles permanentes de peligrosidad** o justificar un trato sistemáticamente más severo a determinados internos.
 - Este uso choca con el **principio de reinserción** (art. 25.2 CE) y con la crítica que el propio documento hace al estigma asociado a sistemas de predicción de crimen (se cita el caso de Chicago como ejemplo a evitar).
2. **Sustituir el criterio profesional por la “opinión” del modelo**
 - Actuar de forma rutinaria en base a la alerta sin comprobar la situación, generando una **dependencia acrítica** de la IA.
 - Contradice el requisito de **supervisión humana efectiva** de la IA Act (art. 14) y los principios de responsabilidad del RGPD.
3. **Uso punitivo o represivo más allá de la finalidad legítima**
 - Ajustar umbrales o interpretar las alertas para **perseguir a determinados colectivos** (políticos, religiosos, étnicos, etc.), incluso si el modelo no usa explícitamente dichas variables.

- Iría contra las advertencias sobre **discriminación indirecta** recogidas en el art. 10 IA Act y en las guías del EDPB sobre uso de vídeo y biometría.
- 4. **Ampliar el alcance de datos sin nueva evaluación (DPIA/EIPD)**
 - Introducir nuevas fuentes de datos (por ejemplo, vídeos reales sin esqueletización previa, datos biométricos o historiales clínicos individualizados) sin:
 - Nueva **Evaluación de Impacto en Protección de Datos (EIPD)**.
 - Evaluación ética externa.
 - Contradice las recomendaciones del EDPS sobre la dificultad de lograr anonimización real y la necesidad de DPIA en contextos de videovigilancia de alto riesgo.
- 5. **Uso como argumento único en decisiones de alto impacto**
 - Emplear la presencia de alertas como **motivo principal o único** para negar permisos, progresiones de grado o beneficios penitenciarios.
 - Se considera un abuso del sistema, incompatible con el marco de **gobernanza del riesgo** que tu documento define (niveles A/B/C, auditorías, canal de reclamaciones, etc.).
- 6. **Despliegue a gran escala ignorando las métricas GO/NO-GO**
 - Mantener el sistema en producción si **no se alcanzan los umbrales definidos** en tu especificación (Recall $\geq 95\%$, FPs $< 12\%$, FNs $< 8\%$, Equalized Odds $< 5\%$, latencia < 500 ms).
 - Desplegarlo masivamente sin cumplir el **Nivel C** de robustez y equidad que describes se consideraría un mal uso, contrario al enfoque **safetyist** explicitado en el apartado de “Postura macro”.