

3. Datos y entrenamiento

3.1. Tipos de datos usados y por qué

PrisonRisk-AI sigue un enfoque **simulation-first**: el modelo se entrena **exclusivamente con datos sintéticos y simulados**, no con vídeos reales de prisiones. Esto se alinea con las consideraciones legales y de protección de datos detalladas en la especificación (RGPD, IA Act, opiniones de la Comisión Europea y EDPB sobre biometría y anonimización).

Tipos de datos y finalidad:

1. Simulaciones de vídeo (visión / esqueletos digitales)

- **Qué son:** escenas generadas con motores físicos y de animación multi-agente, inspiradas en datasets de poses y acciones humanas como:
 - **CMU Panoptic Studio** – poses 3D y acciones humanas [CMU Panoptic](#)
 - **Human3.6M** – poses 3D y actividades cotidianas (referenciado en tu anexo)
 - **NTU RGB+D / NTU RGB+D 120** – reconocimiento de acciones basado en esqueletos (poses 3D de 25 joints).
- **Qué se usa realmente:** el sistema **no conserva la imagen RGB**, solo **esqueletos digitales** (coordenadas y movimiento de articulaciones en el tiempo).
- **Por qué:**
 - Captar patrones de **proximidad, aceleración, invasión de espacio personal y dinámicas de grupo**.
 - Minimizar el riesgo de identificación directa, coherente con el principio de **minimización del art. 5 RGPD** (ver referencias RGPD: [Youreurope – Data Protection](#) y [LOPD-RGPD](#)).

2. Audio sintético (ruido ambiental y eventos sonoros)

- **Qué son:** señales de audio generadas o mezcladas para representar **gritos, golpes, discusiones, ruidos de objetos**, inspiradas en ontologías y etiquetas de conjuntos como:
 - **AudioSet** (Google) – ~2M clips etiquetados de audio ambiental y eventos sonoros [AudioSet](#).
- **Qué se usa realmente:** solo se procesan **rasgos acústicos abstractos** (energía, espectro, picos de volumen, patrones de ruido), sin almacenar voz identificable.
- **Por qué:**
 - Mejorar la detección de **tensión y conflictos** combinando información de movimiento y sonido.
 - Respetar las restricciones del **art. 9 RGPD** sobre datos biométricos para identificación, tal como recuerdan la Comisión Europea y el EDPB en sus guías sobre vídeo y biometría (citadas en el documento principal).

3. Contexto simulado (sensores, densidad, normas)

- **Qué son:** variables sintéticas que representan **densidad de personas, proximidad entre grupos, rutinas, horarios y restricciones espaciales**, en línea con la arquitectura de sensores/IoT descrita en el mockup de arquitectura (Cámaras + Sensores + Audio IoT → Módulo de Preprocesamiento → Modelo de IA Multimodal → Motor de Alertas).
 - **Qué se usa realmente:**
 - Coordenadas relativas, conteo de personas, estados de módulos... todo en formato **anonimizado y abstracto**.
 - **Por qué:**
 - Captar el **contexto operativo** (no es lo mismo un patio amplio que un pasillo estrecho).
 - Ajustar la sensibilidad del modelo en función de la zona y las rutinas, sin tratar identidades personales.
4. **Metadatos operativos (fase de despliegue)**
- **Qué son:** registros como **hora, módulo, tipo de patrón, resultado de la alerta (confirmada/descartada por el funcionario)**.
 - **Por qué:**
 - Permiten auditoría, trazabilidad y mejora continua, en línea con las exigencias de la **IA Act** (arts. 9–11, 13 y 14) y con la obligación de supervisión humana y explicabilidad (referencias:
 - [AI Act – Maldita.es](#)
 - [AI Act Explorer](#)).
-

3.2. Origen de los datasets y criterios mínimos de calidad

Origen de los datos

1. Datasets públicos de referencia

Usados como inspiración técnica y, en algunos casos, como base de pre-entrenamiento (siempre respetando sus licencias de uso investigador):

- **CMU Panoptic Studio** – dataset de poses 3D y acciones humanas.
 - **Human3.6M** – poses y actividades cotidianas.
 - **CMU Motion Capture (CMU Mocap)** – secuencias de movimiento 3D para generar esqueletos sintéticos.
 - **NTU RGB+D / NTU RGB+D 120** – reconocimiento de acciones basado en esqueletos 3D, muy usado para validar encoders de pose.
 - **RWF-2000, XD-Violence, UCF-Crime, OpenViolence** – datasets de violencia y anomalías en vídeo de vigilancia (referenciados en tu anexo como “OpenViolence” y otros conjuntos).
 - **AudioSet** – referencia para eventos acústicos (gritos, golpes, ruidos ambientales).
2. Estos recursos se citan en el documento como parte del apartado “Datasets disponibles y obtención de datos faltantes” y en la sección de evaluación/benchmarks.
3. **Simulaciones multi-agente propias**
- Construidas específicamente para PrisonRisk-AI, combinando:

- Disposición de espacios tipo prisión (módulos, pasillos, patios).
 - Diferentes números de internos, roles y dinámicas (discusiones, aproximaciones bruscas, agresiones).
- Derivan en secuencias de **esqueletos 3D y rasgos acústicos** utilizados para entrenar el modelo multimodal.
- 4. **Fuentes doctrinales y regulatorias sobre datos y biometría**
El diseño de qué datos usar y cómo tratarlos se apoya en referencias legales y técnicas incluidas en el documento:
 - **RGPD / LOPD-GDD:**
 - [Youreurope – Data Protection](#)
 - [LOPD-RGPD](#)
 - **IA Act** (sistemas de alto riesgo, supervisión humana, gestión de datos):
 - [Maldita.es – Ley de IA en la UE](#)
 - [AI Act Explorer](#)
 - **Principio de reinserción (art. 25.2 CE)** y documentación sobre su interpretación .
 - **Informes sobre anonimización y biometría** de la Comisión Europea, EDPB y EDPS (citados en el bloque sobre “tratamiento de imágenes/lecturas biométricas de presos”).

Criterios mínimos de calidad

Un dataset (público o simulado) solo se incorpora al entrenamiento si:

1. **Cubre casos relevantes** (situaciones normales, tensión moderada, altercados) en variedad de escenas.
2. **Presenta diversidad** de patrones de movimiento, morfologías, edades y capacidades, para evitar sesgos sistemáticos.
3. **Tiene etiquetado consistente y revisado**, con validación por consultoras externas cuando sea posible (como se indica en el documento: “Los datos de entrenamiento se validarán por consultorías externas para garantizar representatividad y ausencia de sesgos”).
4. **Permite métricas de equidad** como Equalized Odds (< 5 % de diferencia entre grupos, tal como se explicita en la sección de riesgos y equidad).
5. **Respeto las licencias y el marco legal** (uso investigador, no comercial, respeto al RGPD incluso si hay riesgo de reidentificación teórica).

3.3. Estimación de recursos de entrenamiento (resumen breve)

La especificación del proyecto (sprint 3–4, sección “Estimación del entrenamiento: hardware, coste y huella de carbono”) proporciona los siguientes valores clave:

- **Tamaño del modelo objetivo:**
 - **3.000 millones de parámetros (3B).**
- **Dataset sintético:**
 - Aproximadamente **5.000 horas** de simulaciones multimodales (visión + audio + contexto).
- **Hardware de referencia:**
 - Nodo de entrenamiento con **8× NVIDIA H100.**

- **FLOPs totales estimados:**
 - Aproximadamente **$1,08 \times 10^{21}$ FLOPs** para un entrenamiento completo con granularidad alta (≈ 1000 tokens/s).
- **GPU-hours acumuladas:**
 - En torno a **180 horas GPU**.
- **Coste en la nube (referencias de precios H100 que citas en el anexo):**
 - Con un coste alto estimado de **10 /GPU-h**→**1.800/GPU-h**→**1.800** base.
 - Considerando iteraciones de desarrollo x3 → **~5.400 \$** de coste total de cómputo.

Estas cifras se apoyan en las fórmulas estándar de cómputo para Transformers (FLOPs $\approx 6 \times N_{\text{parámetros}} \times N_{\text{tokens}}$), en las hojas de datos de NVIDIA H100 y en comparativas de precios de GPU en la nube, tal y como se cita en la parte de “Supuestos para las estimaciones cuantitativas” del propio documento.

3.4. Impacto ambiental: huella de carbono resumida

En el mismo apartado de estimación, tu documento proporciona una cuantificación concreta del impacto ambiental de este entrenamiento:

- **Energía consumida:**
 - Aproximadamente **74,25 kWh** para un entrenamiento completo del modelo de 3B parámetros con el dataset de 5.000 h y resolución temporal alta.
- **Huella de CO₂ estimada (España, según mix energético):**
 - Entre **8 y 21 kg de CO₂**, según el factor de emisión (entre 108 gCO₂/kWh y 283 gCO₂/kWh) referenciado en las fuentes energéticas del anexo.

Interpretación:

- Este impacto es **modesto en comparación con grandes entrenamientos de modelos fundacionales** (que pueden implicar toneladas de CO₂), pero no es despreciable si se repiten muchos ciclos de entrenamiento.
- Por eso, la propia especificación recomienda:
 - **Limitar el número de entrenamientos completos**, reutilizando modelos pre-entrenados.
 - Evaluar el uso de **proveedores cloud con alta proporción de renovables** para reducir aún más la huella.