

4. Evaluación y métricas

4.1. Cómo se evalúa si el sistema “funciona”

PrisonRisk-AI se evalúa combinando:

1. Evaluación en laboratorio (simulaciones + benchmarks públicos)

- Entrenamiento y validación sobre **simulaciones no vistas** y sobre conjuntos de referencia de visión/audio/anomalía que citas en el documento, por ejemplo:
 - **NTU RGB+D / NTU RGB+D 120** (acciones/esqueletos 3D).
 - **UCSD Anomaly Detection, RWF-2000, XD-Violence, UCF-Crime, OpenViolence**, etc., listados en la sección de “Datasets disponibles y obtención de datos faltantes”.
 - **AudioSet** para eventos sonoros (gritos, golpes, ruidos ambientales).
- Se calculan métricas estándar de detección (AUC-ROC, F1, tasas de FP/FN, latencia, calibración), siguiendo las fórmulas de cómputo y escalado de modelos expuestas en el anexo de “Estimaciones sobre el entrenamiento” ($\text{FLOPs} \approx 6 \times N_{\text{params}} \times N_{\text{tokens}}$).

2. Evaluación en pruebas controladas en entorno real (piloto)

- Despliegue en **modo piloto** en ciertos centros, sin que las alertas sean todavía la **única base** de decisiones disciplinarias.
- Recogida de indicadores operativos:
 - Número de alertas por módulo/turno.
 - Confirmación o descarte por parte de funcionarios.
 - Falsas alarmas por cámara y por 24 horas (FAR).
 - Tiempo hasta la detección (latencia).
- En paralelo, evaluación de **impacto sobre colectivos vulnerables**, siguiendo la sección 8 de tu documento (personas mayores, personas con discapacidad motora, personas con alteraciones vocales, etc.).

Este enfoque de evaluación está alineado con:

- Las exigencias de **gestión de riesgos, documentación técnica y calidad de datos** de la **IA Act** (arts. 9–11, 13 y 14), según las referencias:
 - [Maldita.es – Ley de IA en la UE](#)
 - [AI Act Explorer](#)
- El principio de **responsabilidad proactiva y minimización de datos** del **RGPD/LOPD-GDD**, que ya citas:
 - [Youreurope – Data Protection \(RGPD\)](#)
 - [LOPD-RGPD – Cumplimiento LOPD](#)

4.2. Métricas clave

Basándonos en las secciones “Evaluación del modelo y criterios go/no-go” y “Métricas concretas” de tu PDF, las métricas principales son:

4.2.1. Métricas funcionales (detección de altercados)

- **Recall (sensibilidad)**
 - Proporción de altercados detectados correctamente.
 - Crítica para seguridad: los **falsos negativos** son especialmente graves.
- **Precision (precisión)**
 - Proporción de alertas que realmente corresponden a altercados o tensiones relevantes.
 - Clave para evitar **alert fatigue** del personal.
- **F1 / F β**
 - Combina precision y recall. En el documento se menciona $F1 > 0,85$ como referencia de calidad en validación previa.
 - Puede adoptarse F β con $\beta > 1$ si se prioriza seguridad (recall).
- **AUC-ROC y AUPRC**
 - El anexo fija como objetivo **AUC-ROC > 0,90**.
 - AUPRC es especialmente útil cuando los altercados son poco frecuentes.
- **False Positive Rate (FPR) y False Negative Rate (FNR)**
 - Tu documento establece explícitamente:
 - **Falsos positivos < 12 %**
 - **Falsos negativos < 8 %**

4.2.2. Métricas operativas

- **Latencia de detección**
 - Tiempo entre el inicio del evento y la primera alerta válida.
 - Objetivo general en la especificación: **latencia < 500 ms** para la canalización multimodal, con estándares más estrictos (por ejemplo $p_{95} \leq 2-3$ s) en los distintos niveles de despliegue.
- **False Alarm Rate (FAR)**
 - Falsas alarmas por cámara y por 24 horas.
 - En tus niveles operativos se menciona, por ejemplo:
 - Para despliegues más exigentes: **$\leq 0,25$ FP / cámara / 24 h.**

4.2.3. Métricas de robustez y seguridad

- **Degradación relativa bajo condiciones adversas**
 - Comparar recall/precision en condiciones normales vs. oclusiones, baja luz, ruido alto, pérdida de modalidad (sin audio o sin ciertas cámaras).
 - En el documento se propone que la degradación no supere el **10–20 %** según nivel (A/B/C).
- **Detección OOD (out-of-distribution)**
 - AUROC para distinguir inputs fuera de la distribución de entrenamiento.
 - Tu anexo propone como referencia **AUROC $\geq 0,9$** para inputs OOD.
- **Calibración**
 - Métricas como **Brier score** y diagramas de fiabilidad, importantes para que las probabilidades mostradas al funcionario (por ejemplo “92 % de probabilidad de conflicto”) se correspondan con frecuencias reales.

Estas métricas se apoyan en la literatura científica y benchmarks referidos en tus anexos (papers sobre RWF-2000, XD-Violence, DCASE, etc.).

4.3. Umbrales “Go/No-Go” para pasar a producción

Tu especificación define **umbrales de aceptación** que condicionan el paso a distintas fases de despliegue. Resumen adaptado:

Nivel A – Mínimo para pruebas de campo (piloto controlado)

- **Recall $\geq 0,85$**
- **Precision $\geq 0,40$**
- **FAR $\leq 1-2$ FP / cámara / 8 h (turno)**
- **Latencia (p95) ≤ 5 s**
- Degradación de rendimiento bajo condiciones adversas **< 30 %**

Permite pilotaje con vigilancia estrecha y revisión manual intensiva.

Nivel B – Despliegue restringido (producción limitada)

- **Recall $\geq 0,90$**
- **Precision $\geq 0,60$**
- **FAR ≤ 1 FP / cámara / 24 h**
- **Latencia (p95) ≤ 3 s**
- **AUPRC $\geq 0,60$**
- Degradación bajo condiciones adversas **< 20 %**
- Diferencias de recall entre subgrupos **< 10 %**

Uso operativo en un número limitado de centros, con auditoría reforzada.

Nivel C – Go/No-Go para despliegue a escala (producción general)

Según el bloque “Nivel C — Go–NoGo para despliegue a escala” de tu documento:

- **Recall $\geq 0,95$**
- **Precision $\geq 0,70$** (o políticas adicionales de verificación humana si se acepta algo menor)
- **FAR $\leq 0,25$ FP / cámara / 24 h**
- **Latencia (p95) ≤ 2 s**
- **AUPRC $\geq 0,75$, AUC-ROC $\geq 0,95$**
- Buena **calibración** (alta precisión en el percentil más alto de scores).
- Degradación bajo condiciones adversas **< 10 %**
- **Equalized Odds** (diferencias de TPR y FPR entre grupos) **< 5 %**

Si no se alcanzan estos valores, el propio documento indica que el sistema **no debe desplegarse a escala**, salvo con fuertes medidas compensatorias (mayor supervisión humana, límites estrictos de uso, etc.), en línea con el enfoque **safetyist** que describís.

4.4. Comprobación de que el modelo no empeora resultados para ciertos grupos (referencia a sección 8)

La sección 8 de tu especificación identifica explícitamente **colectivos vulnerables**:

- Personas mayores con limitaciones de movilidad.
- Personas con discapacidad física o motora atípica.
- Personas con alteraciones vocales o disfonías.
- Combinaciones interseccionales (edad + discapacidad + contexto).

Para comprobar que PrisonRisk-AI **no empeora los resultados** para estos grupos (ni introduce discriminación indirecta), se aplican varios mecanismos ligados a las referencias normativas sobre sesgos:

1. Métricas por subgrupos y Equalized Odds

- Se calculan **recall, precision, FPR, FNR y FAR** para cada subgrupo de interés.
- Se aplica la métrica de **Equalized Odds** (citada en el documento, junto a demographic parity) garantizando que las diferencias entre subgrupos sean:
 - En despliegue a escala: **< 5 %**, tal y como se recoge en la parte de “Equidad – Equalized Odds: diferencia < 5 % entre todos los subgrupos evaluados”.
- Esto responde a las exigencias del **art. 10 IA Act** (calidad y ausencia de sesgos en datos y modelos) y a las guías del **EDPB/EDPS** sobre discriminación indirecta en sistemas automatizados (mencionadas en tu bloque sobre biometría y penitenciarías).

2. Auditorías externas de sesgo

- Según tu sección de “Sesgos y auditorías”, los datos de entrenamiento y el modelo se someten a **consultorías y auditorías externas periódicas**, que revisan:
 - Representatividad de los datos sintéticos.
 - Distribución de errores entre subgrupos (edad, movilidad, patrones vocales, etc.).

3. Generación sintética dirigida para colectivos vulnerables

- En la parte de “Prevención y reparación” (sección 8), indicáis que se hará **“generación sintética activa de movilidad diversa, efectos de medicación, lesiones”** para:
 - Aumentar la **cobertura de casos** de personas con movilidad o voz atípica.
 - Evitar que el modelo aprenda que esos patrones son “anómalos” de forma injustificada.

4. Supervisión humana obligatoria y trazabilidad

- Cada alerta incluye explicación (ej. “aumento del tono de voz + acercamiento brusco”) y se registra junto con la decisión humana.
- Si se detecta que las alertas se concentran injustificadamente en un colectivo (p.ej., internos con discapacidad motora), el DPO o el director pueden activar el **“botón de parada”** definido en el punto 7 (modo seguro + notificación al

Ministerio), en línea con el principio de responsabilidad del RGPD y tu esquema de gobernanza.

5. Compromisos de equidad formales

- En tu documento se fijan compromisos explícitos:
 - **Equalized Odds < 5 %.**
 - **Validación externa semestral.**
 - **Pruebas específicas para perfiles minoritarios.**

Estos mecanismos se apoyan en:

- Las obligaciones de no discriminación y calidad de datos del **AI Act** ([AI Act Explorer](#)).
- Las exigencias del **RGPD** respecto a categorías especiales de datos y tratamiento justo ([Youreurope – Data Protection](#)).