

8. Usuarios, sesgos y colectivos afectados

8.1. Usuarios del sistema y relaciones de poder

Quién usa el sistema directamente

- **Funcionariado y personal de vigilancia de prisiones**
 - Usuarios operativos de PrisonRisk-AI: reciben alertas, las interpretan y deciden si intervenir.
 - Tienen **poder directo** sobre la vida cotidiana de los internos (movimientos, cacheos, sanciones disciplinarias, restricciones de actividades).
- **Equipos directivos de centros penitenciarios y Ministerio del Interior**
 - Definen **políticas de uso**, umbrales de alerta, protocolos de intervención y criterios de evaluación del sistema.
 - Pueden decidir sobre el **despliegue, ampliación o retirada** del sistema.
- **DPO, servicios jurídicos y órganos de cumplimiento**
 - Supervisan el cumplimiento de **RGPD/LOPD-GDD**, la **IA Act** y las salvaguardas éticas (EIPD/DPIA, auditorías, botón de parada).

Quién se ve afectado

- **Personas internas en centros penitenciarios**
 - No usan la interfaz, pero son el colectivo sobre el que el sistema **observa, genera alertas y potencialmente influye en decisiones**.
 - Se encuentran en una situación de **máxima vulnerabilidad**:
 - Privación de libertad.
 - Dependencia total de la institución para condiciones de vida, acceso a derechos, etc.
 - Riesgo de que el sistema refuerce estigmas o genere decisiones injustas.
- **Personal penitenciario**
 - También son afectados:
 - La calidad de las alertas puede influir en su **carga de trabajo, estrés, percepción de seguridad**, y eventualmente en su responsabilidad jurídica si se interpretan mal las alertas.

Relaciones de poder

- Hay una **asimetría estructural** muy fuerte:
 - De un lado, **Estado / Administración penitenciaria + tecnología**.
 - Del otro, **internos**, que tienen capacidad limitada para:
 - Comprender el funcionamiento del sistema.
 - Impugnar decisiones, pedir explicaciones o correcciones.
- Esto refuerza la necesidad de:
 - **Transparencia, explicabilidad y derecho a reclamación**, tal y como exige la IA Act (arts. 13–14) y el RGPD ([Youreurope – RGPD](#)).
 - Una **gobernanza fuerte** con DPO, EIPD/DPIA y botón de parada, como se recoge en vuestra sección de gobernanza.

8.2. Colectivos vulnerables y desigualdad (Model Card + Anexo)

En el **Model Card** se deben listar al menos 3 colectivos clave; en el anexo pueden ampliarse. Basándonos en vuestro texto:

Colectivos mínimos (para Model Card)

1. **Personas mayores y personas con movilidad reducida o atípica**
 - Cambios motrices (pasos cortos, movimientos lentos, temblores, secuelas de lesiones, efectos de medicación).
 - El modelo, centrado en posturas y movimientos (esqueletos), podría **malinterpretar movimientos atípicos** como tensos o agresivos.
2. **Personas con discapacidades físicas o trastornos del movimiento**
 - Tics, espasticidad, movimientos involuntarios, uso de bastones o sillas de ruedas.
 - Riesgo de que se confundan con comportamientos “extraños” o “sospechosos”, según cómo se entrene el sistema.
3. **Personas con alteraciones vocales o problemas de habla**
 - Disfonías, tartamudez, voz muy aguda o muy grave, secuelas de intervenciones médicas.
 - El módulo acústico, si no está bien diseñado, podría asociar ciertos patrones de voz (volumen, tono, irregularidades) a “tensión” o “agresión”.

Colectivos adicionales (para Anexo)

4. **Personas migrantes y minorías étnicas**
 - Aunque el sistema evita campos raciales y no usa color de piel, hay riesgos indirectos:
 - Zonas del centro donde se concentran ciertos colectivos.
 - Estilos de comunicación corporal/cultural diferentes.
 - Riesgo de que, por patrones contextuales, se produzcan más alertas en módulos o patios con alta presencia de personas migrantes.
5. **Personas con trastornos de salud mental o en tratamiento farmacológico**
 - Medicación que altera el movimiento (rigidez, lentitud, temblores) o la expresión emocional / tono de voz.
 - Mayor riesgo de ser interpretados como “anómalos” por modelos entrenados con patrones de movimiento “estándar”.
6. **Personas jóvenes (especialmente varones jóvenes)**
 - Históricamente estigmatizados como más “conflictivos” en contextos penitenciarios.
 - Riesgo de que datos históricos o actitudes del personal influyan en las etiquetas de entrenamiento y en la interpretación de alertas, reforzando sesgos previos.
7. **Interseccionalidad (2+ colectivos)**
 - Personas que combinan varios factores: p.ej.,
 - Hombre joven migrante con trastorno mental.
 - Mujer mayor con discapacidad motora.

- Estos casos pueden sufrir **estratificación de riesgos**:
 - Más probabilidad de aparecer en datos históricos de altercados (real o por sesgo).
 - Más probabilidad de ser vigilados con desconfianza y de recibir sanciones.

El documento reconoce esta dimensión interseccional y la necesidad de **metricar resultados por subgrupos**, así como de usar **Equalized Odds** como medida (diferencia < 5 % entre subgrupos en fase avanzada).

8.3. Fuentes de sesgo potencial y ejemplos prácticos

1) Datos (sub/sobre-representación, etiquetas sesgadas, históricos discriminatorios)

- **Infrarrepresentación en datos sintéticos**
 - Si las simulaciones modelan sobre todo cuerpos “estándar” (jóvenes, sanos, sin discapacidades), el sistema aprenderá **patrones de movimiento dominantes** y tratará otros como raros.
 - Ejemplo:
 - Persona mayor con pasos muy cortos y balanceo de brazos reducido → podría parecer “inestable”, incrementando falsas alertas de tensión.
- **Sobre-representación de ciertos contextos**
 - Si las simulaciones o benchmarks se centran en **escenarios típicos de violencia** (grupos de hombres jóvenes corriendo, empujando, etc.), el sistema puede ser más sensible a:
 - Movimientos bruscos en grupos jóvenes.
 - Físicos y biomecánicas asociadas a cierta edad/género.
- **Etiquetas históricas sesgadas**
 - Aunque el entrenamiento es 100 % sintético, los **escenarios diseñados** pueden inspirarse en ideas preconcebidas (“cómo se ve una pelea”).
 - Si esos guiones se basan en representaciones estereotipadas (p.ej., siempre los mismos tipos de cuerpos en rol agresor), se replica el sesgo.

2) Modelo (umbrales, pesos, reglas)

- **Umbrales de alerta**
 - Elegir umbrales muy bajos para ciertos patrones puede producir más alertas en:
 - Módulos con mucha densidad de población (a menudo con más personas migrantes o más jóvenes).
 - Riesgo: concentrar falsos positivos en ciertos módulos/grupos.
- **Arquitectura y pérdida**
 - Un modelo que penalice más los **falsos negativos** que los **falsos positivos** podría, si no se monitoriza por subgrupos,
 - sobre-alertar en grupos ya estigmatizados,
 - o ignorar más fácilmente señales suaves de tensión en grupos infrarrepresentados.

3) Producto (interfaz, defaults, idioma, canal de reclamaciones)

- **Interfaz y defaults**
 - Si la GUI destaca más visualmente ciertos módulos o tipos de alerta, el personal podría **prestar más atención a unos grupos que a otros**, amplificando sesgos.
 - Si los parámetros son difíciles de interpretar, el funcionario tiende a **seguir lo que dice el sistema** sin espíritu crítico.
- **Idioma y accesibilidad del canal de reclamaciones**
 - Si la información sobre el sistema y el canal de reclamaciones está solo en un idioma, o en lenguaje muy técnico,
 - dificulta que internos migrantes o con bajo nivel educativo puedan entender y cuestionar el sistema.

8.4. Prevención y reparación: qué se ha decidido hacer

El documento plantea una estrategia dual **prevención + reparación**, coherente con el art. 10 IA Act y el principio de responsabilidad proactiva RGPD:

Prevención

1. **Entrenamiento 100 % sintético con diversidad explícita**
 - Generar **escenarios sintéticos específicos** para:
 - Movilidad diversa (personas mayores, discapacidad motora, efectos de medicación).
 - Voces atípicas (disfonías, habla entrecortada).
 - Esto se menciona en vuestra especificación como:
 - *“Generación sintética activa de movilidad diversa, efectos de medicación, lesiones”.*
2. **Exclusión de variables de raza/etnia y biometría identificable**
 - No se usan color de piel, rasgos faciales, ropa o tatuajes.
 - No se emplea reconocimiento facial ni de voz, alineado con las advertencias de Comisión Europea, EDPB y EDPS.
3. **Diseño de umbrales y política de alertas con enfoque conservador**
 - Umbrales pensados para **equilibrar seguridad y falsos positivos**, monitorizando su efecto por subgrupos.
 - No se aceptan configuraciones que generen FAR o FP desproporcionados en módulos concretos.
4. **Interfaz con explicaciones claras**
 - Cada alerta debe mostrar **qué patrones han motivado** la predicción (ej. “aumento brusco de proximidad + tono de voz alto + gestos expansivos”).
 - Evita que se perciba como “caja negra” y facilita la **corrección humana** de sesgos.

Reparación y corrección

5. **Monitorización por subgrupos e interseccionalidad**

- Cálculo regular de métricas por grupos: edad, movilidad, tipo de módulo, etc.
 - Detección de patrones de error discriminatorios y reajuste (re-training, recalibración).
6. **Auditorías externas periódicas de sesgo**
- Consultoras o grupos académicos independientes revisan:
 - Datos sintéticos y escenarios.
 - Distribución de errores y métricas de equidad.
7. **Botón de parada y revisión extraordinaria**
- Si se detectan **sesgos graves o sistemáticos**, el DPO o el director pueden activar el **modo seguro** y detener el sistema (ver sección 7), abriendo una revisión integral.
8. **Canal de reclamaciones accesible**
- Usuarios indirectos (internos, defensores, ONG) pueden señalar:
 - Casos concretos donde una alerta parezca injusta o sistemáticamente dirigida a un grupo.
 - Estas reclamaciones se integran en el ciclo de mejora del sistema.

8.5. Compromisos de diseño a favor de la equidad

Vuestro documento recoge varios compromisos concretos:

1. **No identificación ni ranking de peligrosidad individual**
 - El sistema solo genera alertas situacionales/contextuales, no **scores permanentes de riesgo por persona**.
2. **No decisiones automáticas**
 - Siempre hay **intervención humana significativa**, alineada con art. 14 IA Act.
3. **Modelado inclusivo en simulaciones**
 - Inclusión de **cuerpos, edades y patrones de movilidad diversos** en datos sintéticos.
4. **Métricas de equidad integradas desde el diseño**
 - No se deja la equidad como “post-hoc”: Equalized Odds y métricas por subgrupo forman parte del **checklist para pasar de nivel A → B → C**.
5. **Prioridad a la protección de colectivos estructuralmente vulnerables**
 - En caso de trade-off, se priorizan soluciones que **no empeoren la situación de quienes ya están peor situados** (edad, discapacidad, migración, salud mental).

8.6. Métricas de equidad y mínimos auto-impuestos

De acuerdo con tu especificación (sección de métricas y equidad):

- **Equalized Odds (EO)**
 - Se mide la diferencia en:
 - **TPR (recall)** y

- **FPR (false positive rate)**
entre subgrupos (edad, movilidad, módulo, etc.).
 - Objetivos:
 - En despliegue a escala (Nivel C): **EO < 5 %** entre todos los subgrupos evaluados.
 - En fases intermedias (Nivel B): tolerancia máxima **< 10 %**.
- **Métricas funcionales por subgrupo**
 - **Recall, precision, FPR, FNR** calculadas por:
 - Personas mayores vs. no mayores.
 - Movilidad atípica vs. estándar.
 - Módulos con mayor presencia de migrantes, etc.
 - Si se detectan diferencias significativas, el sistema debe:
 - Re-entrenarse.
 - Ajustar umbrales.
 - O, en casos graves, detenerse (botón de parada).
- **Validación externa periódica**
 - Al menos **semestralmente**, una entidad externa revisa:
 - Métricas de equidad.
 - Configuraciones de umbrales.
 - Informes de reclamaciones y paradas.
- **Mínimos auto-impuestos**
 - No despliegue a escala sin:
 - **Equalized Odds < 5 %**.
 - **Recall ≥ 0,95** global.
 - **FAR ≤ 0,25 FP / cámara / 24h**.

Fuentes normativas:

- IA Act (calidad de datos, ausencia de sesgos, art. 10): [AI Act Explorer](#)
- RGPD y principio de responsabilidad (art. 5.2): [Youreurope – Data Protection](#)