

Model Card: PrisonRisk-AI

1. Resumen del Modelo y del Proyecto

Nombre del Proyecto/Sistema: PrisonRisk-AI **Versión:** 1.0 (Estimada) **Fecha de Despliegue Prevista:** 2029 **Autores:** Grupo 3 (Rodrigo Jesús-Portanet Martínez, Hamza Triki, Daniel Coletto Quereda, João Francisco Sampaio Pereira, Carlos Mantilla Mateos), **Actor Representado:** Desarrolladores del Algoritmo de Inteligencia Artificial.

Descripción Concisa (One-Liner): Algoritmo de IA para evaluar, predecir y prevenir altercados entre internos en centros penitenciarios.

Objetivo Principal y Problema Social: El objetivo principal es **predecir el riesgo de altercados entre presos** para mejorar la seguridad y la **gestión preventiva** en centros penitenciarios, enfocándose en la detección temprana de patrones de tensión o riesgo de violencia.

Origen de la idea y diferenciación: Inspirado en el proyecto de Chicago “Algorithm to Predict Crime”, pero no se aplica a población general, sino exclusivamente a prisiones de media y alta seguridad en España, con:

- **Entrenamiento 100 % sintético**, no basado en vídeos reales.
- **Ausencia total de datos identificables.**
- Diseño explícito contra sesgos (equalized odds desde la base).

Tipo de modelo

- Modelo de aprendizaje supervisado multimodal basado en:
- **Temporal Graph Neural Networks (TGNN)** o **Spatio-Temporal Transformers** para secuencias de pose.
- Fusión multimodal mediante **Transformer** (audio sintético, proximidad, contexto).

2. Casos de Uso Previstos y No Previstos

Usos previstos

- Generación de alertas interpretables para el personal penitenciario.
- Apoyo a la toma de decisiones humanas en vigilancia preventiva.
- Mejora de la conciencia situacional del centro.

Usos no recomendados / Malos usos previsibles

- **Decisiones automáticas** de sanción, aislamiento o clasificación.
- Uso del sistema como **prueba judicial o disciplinaria.**
- Etiquetado de internos como “peligrosos” o similares.
- Uso fuera del entorno penitenciario definido.

Usuarios previstos

- Administración penitenciaria.
- Funcionarios/vigilantes de prisiones.
- Los internos son el colectivo sujeto a supervisión.

3. Datos y Entrenamiento

PrisonRisk-AI adopta un enfoque simulation-first (no usa datos reales en el entrenamiento):

Tipo de dato	Finalidad	Minimización
Simulaciones de video	Extraer poses, distancias y patrones grupales	Solo esqueletos digitales
Audio sintético	Detectar picos., gritos simulados, tensiones	Solo rasgos acústicos abstractos
Contexto simulado (IoT, proximidad, normas)	Modelar densidad, rutinas, interacciones	Coordenadas relativas y variables anonimizadas

Origen y calidad

- **Simulaciones multi-agente** generadas con motores físicos y animación procedimental.
- Permiten generar **millones de casos variando edad, complexión, movilidad, discapacidad, patrones culturales**.
- Validación por consultoras externas para evitar sesgos estructurales.
- **Prohibición total** de usar vídeos reales en entrenamiento o fine-tuning.

Recursos de entrenamiento

- Modelo: **≈ 3B parámetros**
- Dataset sintético: **5.000 h de simulaciones**
- Hardware: **8× Nvidia H100**
- Tiempo acumulado: **≈ 180 horas GPU**
- Coste estimado: **\$5.400**

Impacto ambiental

- Energía: **74.25 kWh**
- Huella estimada en España: **8–21 kgCO₂**

4. Evaluación y Métricas

Evaluación funcional

- Pruebas controladas en simulaciones no vistas.
- Validación externa de sesgo.

Umbrales GO/NO-GO

- **Recall > 95 %**
- **Falsos positivos < 12 %**
- **Falsos negativos < 8 %**

- Latencia < 500 ms

Equidad

Se aplica **Equalized Odds** con diferencia < 5 % entre todos los subgrupos evaluados (edad, movilidad, patrones vocales, etc.).

5. Privacidad y Protección de Datos

Nivel de riesgo

Clasificado como **Alto Riesgo** según IA Act.

Principios GDPR/LOPD aplicados

1. **Base legal:** Seguridad pública (Art. 6.1.e y 9.2.g RGPD).
2. **Minimización estricta:** Solo datos sintéticos para entrenamiento.
3. **Datos sensibles:** Únicamente esqueletos digitales y rasgos acústicos abstractos; no existe información identificable.
4. **Retención:**
 - Simulaciones de entrenamiento: retención ilimitada (no son datos personales).
 - Registros operativos (metadatos de alertas): **máx. 2 años**.

Medidas estrella de protección

- **Anonimización total en la fuente:** el sistema operativo no accede a imágenes reales.
- **Cifrado AES-256 en todos los logs y metadatos.**
- **EIPD** y supervisión continua por el **DPO**.

6. Propiedad Intelectual y Modelo de Apertura

Licencias

Componente	Licencia	Notas
Código Fuente	GPL-v3	Fomenta auditabilidad ética
Pesos del modelo	Open Weights con cláusulas éticas	Se permite investigación, no usos punitivos
Datos sintéticos	Copyright	Uso restringido
Documentación	CC BY 4.0	Difusión libre con atribución

Modelo de negocio

Servicios profesionales (auditorías, soporte, personalización) sin vendor lock-in.

7. Riesgos, Límites y Gobernanza

Top 5 riesgos

1. **Sesgo** algorítmico residual en **movilidad atípica**.
2. **Falsos negativos** en situaciones reales no reflejadas en la simulación.
3. **Falsos positivos** con efectos injustos sobre internos.
4. **Fuga** o **acceso indebido** a metadatos operativos.
5. Riesgo **psicosocial** por hiper-vigilancia.

Líneas rojas

- No decisiones automáticas.
- No datos biométricos reales.
- No uso judicial o disciplinario.
- No exportación de datos fuera del sistema penitenciario español.

Botón de parada

- **Quién:** Director del centro o DPO.
- **Cuándo:** Brechas graves o FP > 20 %.
- **Cómo:** Activación de “modo seguro” y notificación al Ministerio.

Rendición de cuentas

- Canal interno de reclamaciones con respuesta en **15 días**.
- Corresponsabilidad: Ministerio del Interior + proveedor (Art. 26 RGPD).

8. Usuarios, Sesgos y Colectivos Afectados

Relaciones de poder

- Funcionarios deciden; la IA solo alerta.
- Los internos pueden verse afectados indirectamente.
- Los desarrolladores deben garantizar equidad, transparencia y respeto.

Colectivos vulnerables (mínimo 3)

- Personas mayores con limitaciones de movilidad.
- Personas con discapacidad física o motora atípica.
- Personas con alteraciones vocales o disfonías.
- Interseccionalidad: combinación de edad + discapacidad + factores contextuales.

Análisis de sesgos

Riesgos detectados:

- Infrarrepresentación de patrones motores extremos.
- Sobrerreacción ante anomalías acústicas involuntarias.

Prevención y reparación

- Generación sintética activa de movilidad diversa, efectos de medicación, lesiones.
- Ajuste dinámico de umbrales por centro.
- Supervisión humana obligatoria.
- Trazabilidad y explicabilidad de cada alerta.

Compromisos de equidad

- Equalized Odds < 5 %.
- Validación externa semestral.
- Pruebas específicas para perfiles minoritarios.

9. Limitaciones, Dudas Abiertas y Pasos Futuros

Limitaciones

- Riesgo residual de sesgo pese a la simulación masiva.
- Las simulaciones no cubren todos los comportamientos reales.
- Riesgos de reidentificación teórica en logs (muy bajo).
- Vulnerabilidad a ataques adversariales.

Qué no pretende hacer

- No sanciona, clasifica ni identifica personas.
- No analiza raza, rostro, huellas ni biometría.
- No es prueba judicial ni disciplinaria.

Pasos futuros (Enfoque **safetyist):**

- Refuerzo de auditoría externa independiente.
- Mejora de la robustez adversarial.
- Evaluación continua del impacto psicosocial.

Los anexos donde ampliamos la información se pueden encontrar en nuestro [Github](#), específicamente en el directorio sprint4/.